

# 发现贝叶斯市场对智能资产配置的看法

Frank Z. Xing<sup>1</sup>, Erik Cambria<sup>1</sup>, Lorenzo Malandri<sup>2</sup>和Carlo Vercellis<sup>2</sup>

<sup>1</sup>南洋理工大学计算机科学与工程学院

<sup>2</sup>米兰理工大学数据挖掘与优化研究组

{zxing001, 坎布里亚} @ ntu.edu.sg

{lorenzo.malandri, carlo.vercellis}

@polimi.it

**抽象。**随着意见挖掘技术的发展，公众情绪已被发现是股市预测的关键因素。然而，很少讨论市场参与者的行为如何受到公众情绪的影响。因此，在利用公共情绪来解决资产配置问题方面几乎没有什么进展，这在可信和可解释的方式中是首选的。为了解决从社交媒体中分析公众情绪的问题，我们建议将公众情绪形式化为市场观点，因为市场观点可以融入现代投资组合理论。在我们的框架中，最佳市场观点将通过贝叶斯资产配置模型最大化每个时期的回报。我们训练两个神经模型来生成市场观点，并在其他流行的资产配置策略上对模型性能进行基准测试。我们的实验结果表明，市场观点的形式化显着提高了模拟投资组合在特定风险水平下的盈利能力（每年5%至10%）。

**关键词：**市场观，公众情绪，资产配置

## 1 介绍

销售和宏观经济因素是股市走势背后的推动力，但还有很多其他因素。例如，市场参与者的主观观点也具有重要影响。随着过去几十年社交媒体的日益普及，人们倾向于快速表达和交流他们的想法和意见[21]。结果，他们的观点的重要性急剧上升[6]。目前，股票走势被认为主要受到新信息和投资者信念的影响[17]。

同时，情绪分析已成为分析社交媒体上分享观点的新工具[7]。它是情感计算研究的一个分支，旨在将自然语言的话语分类为正面或负面，但有时也是中性的[9]。在金融领域，情绪分析经常用于获取公司、股票或经济的公共情绪数据流。公共情绪是个人情绪的集合，可以从各种来源获得和估计，例如股票留言板[2,19]，博客，报纸和真正简单的联合供稿[RSS] [34]。

最近, Twitter已经成为一个占主导地位的微博平台, 许多作品都依赖于这些平台进行调查, 例如[27,23,20]. 许多先前的研究支持公众情绪有助于预测股市的说法。例如, 考虑公共情绪的模糊神经网络模型在预测市场指数方面具有较高的方向性。情绪时间序列也被证明是市场指数的格兰杰原因[4]. Si等人。构建基于主题的情绪时间序列, 并使用向量自回归模型更好地预测市场指数, 以交互式链接两个系列[26]. 赫斯特的指数也暗示了从财经新闻中提取的情绪时间序列的长期依赖性, 类似于许多市场指数[8].

尽管股票市场预测具有重要作用, 但我们认为公众情绪不会直接影响市场: 它通过市场参与者的观点间接地做到了。市场参与者作为代理人采取的行动取决于他们自己的观点, 以及他们对其他代理人观点的了解。资产价格的变化是此类行为的后果。这些假设与使用生产率, 均衡和商业周期模型的计量经济学研究有很大不同[1], 但更接近基于代理的模型[14]. 然而, 即使在后一种情况下, 市场观点如何由公众情绪形成的机制也被严重忽视。一个直观的假设可能是: 公众情绪越快, 股价就越高。然而, 在现实市场中, 这种关系要复杂得多。因此, 人工智能的现有表面金融应用似乎并不令专业人士信服。

在本文中, 我们试图通过提出一种结合公众情绪以计算形成市场观点的方法来填补这一空白。为了验证我们的观点质量, 我们使用构建的投资组合模拟交易表现。本文的主要贡献可归纳如下:

1. 我们基于贝叶斯资产分配模型引入了更严格且更易于计算的市场视图定义。我们证明我们的定义是兼容的, 并且具有与原始形式相同的表达能力。
2. 我们提出了一种新的在线优化方法, 通过求解投资组合收益的时间最大化问题来估计预期收益。
3. 我们的实验表明, 混合公共情绪数据流的市场观点的投资组合表现优于直接训练没有观点的神经交易模型。对于使用正确参数选择的不同模型, 这种优势是稳健的, 以产生市场观点。

本文的其余部分安排如下: Sect. 2 解释了贝叶斯资产配置的概念; 接下来, 我们将介绍为Sect中的市场视图建模而开发的方法。3; 我们通过在Sect中运行具有各种实验设置的交易模拟来评估这些方法。4 并通过Sect中的一个例子展示了我们模型的可解释性。5; 最后, Sect. 6 总结了论文并描述了未来的工作。

## 2 贝叶斯资产配置

投资组合构建框架[18]半个多世纪以来，它一直是投资的普遍模式。鉴于初始资本金额，投资者需要将其分配给不同的资产。基于资产收益率与投资者承担的风险之间的权衡，均值方差法提出了一个有效投资组合的条件如下[18,29]:

$$\begin{aligned} & \text{最大化} \quad \overline{\mu} - \frac{\delta}{2} \overline{\sigma^2} \\ & \text{受制于} \quad w_i = 1, i = 1, 2, \dots, N. \quad w_i \geq 0. \end{aligned} \quad (1)$$

其中  $\delta$  是风险规避的指标， $w_i$  表示投资组合中相应资产的权重， $\mu_i$  表示资产  $i$  的预期收益， $\sigma_{ij}$  是资产  $i$  和  $j$  的收益之间的协方差。因此，有效投资组合的优化权重由方程1的一阶条件给出。1:

$$w^* = (\Sigma)^{-1} \mu \quad (2)$$

其中  $\Sigma$  是资产收益的协方差矩阵， $\mu$  是预期收益  $\mu$  的向量。在持有  $w^*$  的风险水平下，有效投资组合实现了最大的组合预期回报。


然而，当在实际情况中应用这种均值 - 方差方法时，面临许多问题。例如，资产收益的两个时刻很难准确估计[25]，因为它们是非平稳的时间序列。由于Markowitz模型对作为输入的估计收益和波动率非常敏感，因此情况更加恶化。由于  $\mu$  或  $\Sigma$  的误差很小，优化后的权重可能会有很大差异。为了解决Markowitz模型的局限性，Black和Litterman提出了一种贝叶斯方法，该方法整合了投资者判断和市场基本面的附加信息[3]。在Black-Litterman模型中，预期收益投资组合的  $\mu_{bl}$  由两个前因推断：由资本资产定价模型（CAPM）计算的市场均衡风险溢价  $\Pi$ ，以及投资者预期收益的一组观点。

Black-Litterman模型假设均衡收益正常分布为  $r_{\text{均衡}}(\Pi, \tau \Sigma)$ ，其中  $\Sigma$  是资产收益的协方差矩阵， $\tau$  是  $\Pi$  的CAPM估计的置信水平的指标。市场对投资者代理人持有的预期回报的看法也通常分配为  $r_{\text{意见}}(Q, \Omega)$ 。

随后，投资组合的后验分布返回提供的视图也是高斯分布。如果我们用  $r_{bl}(\bar{\mu}, \bar{\Sigma})$  表示这种分布，则  $\bar{\mu}$  和  $\bar{\Sigma}$  将是上述变量的函数（见图2）。1).

$$\bar{\mu}, \bar{\Sigma} = f(\tau, \Sigma, \Omega, \Pi, Q) \quad (3)$$

图1. Black-Litterman模型中预期收益的后验分布，其具有两个先前分布之间的平均值，并且方差小于两个先验分布。



通过将贝叶斯定理应用于后验预期收益的概率密度函数，可以推导出该函数：

$$pdf(r_w) = \frac{pdf(m \sim m)}{pdf(p/\mu)} \quad (4)$$

然后，优化的贝叶斯投资组合权重具有与方程式相似的形式。2，只用  $\Sigma$  和  $\mu$  代替  $\Sigma$  和  $\mu$ ：

$$w_{bs} = (\delta \Sigma)^{-1} \mu \quad (5)$$

对Black-Litterman模型最常见的批评是投资者观点的主观性。换句话说，该模型采用了市场观点的良好质量，同时留下了如何实际形成这些未被回答的观点的问题。在Sect. 3，我们将研究从网络中提取的公众情绪自动形式化市场观点的可能性以及每个时期的投资组合回报最大化。

### 3 方法

#### 3.1 市场观建模

Black-Litterman模型将视图定义为一个陈述，即投资组合的预期收益具有正态分布，均值等于 $q$ ， $\omega$ 给出标准差。这个假设的投资组合称为观点投资组合[13]。在实践中，市场上有两种直观的观点类型，称为相对观点和绝对观点，我们特别感兴趣。接下来，我们介绍这两种观点的形式化。

因为标准差 $\omega$ 可以解释为视图投资组合的预期收益的置信度，相对观点采取“我有 $\omega_1$ 信心的形式，资产 $x$ 将超过资产 $y$ 的百分比（就预期收益而言）”；绝对观点采取“我有 $\omega_2$ 信心，资产 $z$ 将超过（整个）市场 $b\%$ ”的形式。因此，对于由 $n$ 个资产组成的投资组合，一组 $k$ 个视图可以由三个矩阵 $P_{k,n}$ ， $Q_{k,1}$ 和 $\Omega_k$ ， $k$ 表示。

$P_{k,n}$  表示视图中提到的资产。 $P_{k,n}$  每行的总和应为0 (对于相对视图) 或1 (对于绝对视图);  $Q_{k,1}$  是包含每个视图的预期回报的向量。数学上, 置信矩阵  $\Omega_{k,k}$  是视图之间协方差的度量。Black-Litterman模型假设视图彼此独立, 因此置信矩阵可写为  $\Omega = \text{diag}(\omega_1, \omega_2, \dots, \omega_n)$ 。实际上, 只要k个视图是兼容的 (不是自相矛盾的), 这个假设就不会影响视图的表达性。因为当  $\Omega_{k,k}$  不是对角线时, 我们总是可以进行频谱分解:  $\Omega = V \Omega' V^{-1}$ 。然后我们写下新的提及和新的预期返回矩阵为  $P' = V^{-1}P$ ,  $Q' = V^{-1}Q$ , 其中  $\Omega'$  是对角线。在这些结构下, 我们介绍了视图的两个重要属性定理中的矩阵1 和定理2。

**定理1 (独立视图的兼容性)。** 任何一组独立视图都是兼容的。

**证明。** 兼容视图指的是可以同时保存的视图。例如, 资产x的表现将优于资产y 3%, 资产y的表现将优于资产z 5%, 资产x的表现将优于资产z 8%兼容。但是, 如果我们将第三个视图更改为 “资产z将超过资产x 8%”, 则视图集会变得自相矛盾。因为第三段视图实际上是前两者的推论, 所以视图集称为 “不独立”。

假设存在一对不相容的视图p, q和p, q<sup>i</sup>;  $q = q^i$ 。两个视图都是明确陈述的, 或者可以从一组k个视图中导出。因此, 存在两种不同的线性组合, 例如:

$$\begin{aligned} \sum_{i=1}^k a_i p_i &= p & \sum_{i=1}^k a_i q_i &= q \\ \sum_{i=1}^k b_i p_i &= p & \sum_{i=1}^k b_i q_i &= q^i \end{aligned}$$

其中  $(a_i - b_i)$  并非都是零。

因此, 我们

$\sum_{i=1}^k (a_i - b_i) p_i = 0$

因此, 我们  $(a_i - b_i) p_i = 0$ , 这意味着矩阵P缺乏秩并且k个视图不是独立的。根据相反的规律,

声明 “所有独立视图集兼容” 是真的。 □

**定理2 (绝对视图矩阵的普遍性)。** 可以用非奇异绝对视图矩阵表示任何一组独立的相对和绝对视图。

**证明。** 假设具有r个相对视图和 (k-r) 绝对视图的矩阵P.

$$\begin{aligned} & p_{1,1} \ p_{1,2} \ \dots \ p_{1,n} \\ & \vdots \\ & p_{k,n} = p_r, \ 1p, \ 2 \bullet \bullet \bullet pr, \ n \\ & \vdots \\ & h_{p, \ 1 \text{ 马力}, \ 2 \cdot PK,} \\ & h_{p, \ 1 \text{ 马力}, \ 2 \cdot PK,} \end{aligned}$$



对应的返回向量是  $Q = (q_1, q_2, \dots, q_k)$ ，资产的资本权重向量是  $w = (w_1, w_2, \dots, w_k)$ 。因此，我们可以写出关于  $r$  个新变量  $\{q_{1i}, q^i, \dots, q_{re}^i\}$  的  $(r+1)$  方程，其中  $j = 1, 2, \dots, r$ ：

$$1 + q_j = \sum_{i=1}^r (1 + q_i) \frac{w_i}{w_s} (1 + q_j) \quad s \neq j$$

$$\sum_{i=1}^r q_{i1} w_i + \sum_{i=r+1}^k q_i w_i = Q w^T$$

如果我们考虑  $\{\text{资产}_{r+1}, \dots, \text{资产}_k\}$  为一项资产，该资产的收益由  $P_{r,n}$  决定。因此，上述  $(r+1)$  方程中的  $r$  是独立的。

根据Cramer的规则，存在一个独特的解  $Q^i = (q_{1i}^i, q_{2i}^i, \dots, q_{ri}^i, q_{r+1i}^i, \dots, q_{ki}^i)$  上述  $(r+1)$  个方程，使得视图矩阵  $\{P^i, Q^i\}$  相当于所有考虑资产的视图矩阵  $\{P, Q\}$ ，其中

$$P_{k,n}^i = \begin{pmatrix} 1 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & p_{r,r} = 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ p_{k,1} & p_{k,2} & \cdots & p_{k,n} \end{pmatrix}$$

现在， $P_{k,n}$  只包含绝对视图。删除这些从属意见，我们可以有一个非奇异矩阵，它只包含绝对视图兼容。

给定定理1和定理2在不失一般性的情况下，我们可以使用以下等价但更严格的市场视图定义来降低计算复杂性。

定义1. 对  $n$  个资产的市场观点可用三个矩阵  $P_{n,n}$ 、 $Q_{n,1}$  和  $\Omega_{n,n}$  表示，其中  $P_{n,n}$  是一个单位矩阵； $Q_{n,1} \in R^n$ ； $\Omega_{n,n}$  是非负对角矩阵。

□

### 3.2 置信度矩阵

在Black-Litterman模型的最原始形式中，置信矩阵  $\Omega$  根据投资者的经验手动设置。而在[给出的数值例子中]13]，置信矩阵是从均衡协方差矩阵推导出来的：

$$\hat{\Omega} = P(\tau \Sigma)P^T \quad (8)$$

这是因为  $P(\tau \Sigma)P^T$  也可以理解为视图中预期收益的协方差矩阵。使用我们的定义，更容易理解这种估计，因为  $P$  是单位矩阵， $P(\tau \Sigma)P^T$  已经是对角线。基本假设是资产  $i$  的绝对视图的方差是与资产的波动率成正比  $i$ 。在这种情况下， $\Omega$  的估计利用过去的资产价格波动信息。

### 3.3 最佳市场观点

我们以混合方式获得最佳市场视图 $P$ ,  $Q$ ,  $\Omega$ , 首先我们采用置信矩阵 $\Omega$ , 然后可以使用Black-Litterman模型从逆优化问题导出 $Q$ .

我们从最优投资组合权重开始, 最大化每个时期 $t$ 的投资组合回报。显然, 如果没有卖空和交易费用, 人们应该每天将其全部资金重新投入到下一时期增长最快的资产中。

因此, 每个时间段 $t$ 的最佳保持权重采用单热矢量的形式, 其中0和0表示元素划分和乘积:

$$w_{t*} = \underset{w_t}{\operatorname{argmax}} w_t \text{ 价格}_t \text{ 价格}_{t+1} \quad (9)$$

9) 设 $w_{t*}$ 为方程式的解。1, 我们将有:

$$w_{t*} = (\tau \Sigma_t)^{-1} \mu \quad (10)$$

Black-Litterman模型给出的地方<sup>3</sup>:

$$\bar{\Sigma}_t = (\tau \Sigma_t)^{-1} + P^T \hat{\Omega}_t^{-1} P \quad (11)$$

$$\bar{\mu}_t = [(\tau \Sigma_t)^{-1} + P^T \hat{\Omega}_t^{-1} P]^{-1} [(\tau \Sigma_t)^{-1} \Pi_t + P^T \hat{\Omega}_t^{-1} Q_t] \quad (12)$$

根据Eq. 10, 11, 和12, 我们每个时期 $t$ 的市场观点的最佳预期回报是:

$$\begin{aligned} Q_t^* &= \hat{\Omega}_{0,t} [(\tau \Sigma_t)^{-1} + P^T \hat{\Omega}_{0,t}^{-1} P] \bar{\mu}_t - (\tau \Sigma_t)^{-1} \Pi_t \\ &= \delta [\hat{\Omega}_{0,t}^{-1} \Pi_t + I] \Sigma_t^{-1} w_{t*} - \hat{\Omega}_{0,t}^{-1} \Pi_t \\ &= \delta [\hat{\Omega}_{0,t} (\tau \Sigma_t)^{-1} + I] [\Sigma_t + [(\tau \Sigma_t)^{-1} + \hat{\Omega}_t^{-1}]^{-1}] w_t^* \\ &\quad - \hat{\Omega}_{0,t} (\tau \Sigma_t)^{-1} \Pi_t \end{aligned} \quad (13)$$

### 3.4 用神经模型生成市场观点

式. 13 提供了确定最佳市场观点的预期回报的理论视角。然而, 计算 $w_{t*}$ 需要未来的资产价格, 这是无法获得的。因此, 可行的方法是用历史数据和其他先验作为输入来学习近似 $Q_t$ 。我们使用资产价格, 交易量和公共情绪数据流的时间序列来训练神经模型

(nn) 关于最佳市场观点的近似问题:

$$\hat{Q}_t = \text{神经网络}(\text{价格}_{t-k}, \text{交易量}_{t-k}, \text{情绪}_{t-k}) \quad (14)$$

我们用滞后算子 $L^{0 \sim k}$ 价格表示资产价格 $t-k$ , 价格 $t-k+1$ , ..., 价格 $t$ 的时间序列。交易量的表示遵循类似的形式。

<sup>3</sup>Eq. 的证明. 11 和12 可以从[附录]找到24].

然后在每个时间点输入模型:  $[L^{0 \sim k} \text{价格}_t, L^{0 \sim k} \text{交易量}_t, \text{情绪}_t, \text{资本}_t]$  可以用  $[p, v, s, c]$  表示<sub>t</sub> 简而言之。

训练两种类型的神经模型, 包括神经模糊方法和深度学习方法进行比较。图. 2 提供了使用长短期记忆 (LSTM) 网络的在线培训过程的说明, 其中  $\hat{Q}$  是输出。

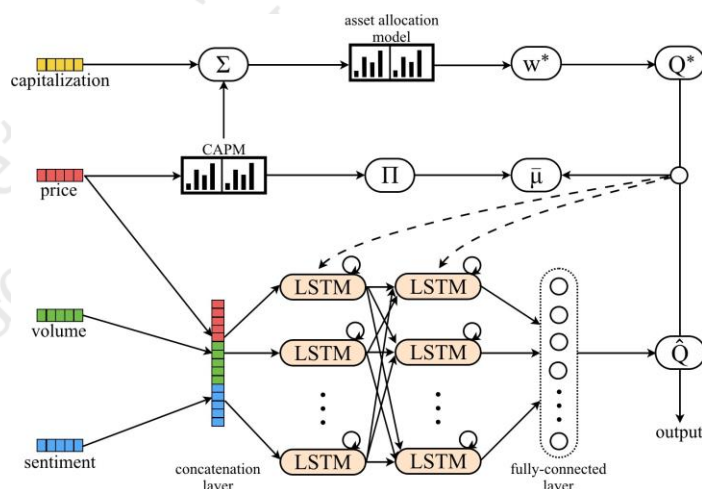


图2. 带有/不带情绪信息的模型培训过程 (LSTM)。

动态演化神经模糊推理系统 (DENFIS) 是一种具有模糊规则节点的神经网络模型 [16]. 使用新的传入数据分布动态更新要激活的规则节点的分区。这种不断发展的聚类方法 (ECM) 具有稳定性和快速适应性的模型。与许多其他模糊神经网络相比, DENFIS 在非线性复杂系统建模方面表现更好 [32].

考虑到金融市场是一个真实世界的复杂系统, 我们在线学习一阶 Takagi-Sugeno-Kang 类型规则。每个规则节点都具有以下形式:

$$\begin{aligned} \text{IF } L^{0 \sim k} \text{ 属性}_{t,i} = \text{模式}_i, \quad i = 1, 2, \dots, N \\ \text{那么 } \hat{Q}_t = f_{1,2,\dots,n}([p, v, s]_t) \end{aligned}$$

其中我们有 3 个属性和  $(2^n - 1)$  候选函数来激活。在我们对 DENFIS 模型的实现中, 所有隶属函数都是对称的和三角形的, 可以用两个参数  $b$  和  $d$  来定义。  $b$  是会员资格等于 1 的地方;  $d$  是激活范围

±



模糊规则。在我们的实现中，b通过现有后续函数系数的线性最小二乘估计来迭代地更新。

LSTM是一种具有门控单元的递归神经网络。据称该单元体系结构非常适合于学习预测具有未知大小滞后和长期事件依赖性的时间序列。早期尝试虽然不是很成功[11]已经使LSTM应用于时间序列预测。现在已经认识到虽然LSTM细胞可以有許多变种，但它们在任务中的表现是相似的[12]。

因此，我们使用香草LSTM单元结构。我们对LSTM单元的实现遵循输入门，忘记门和输出门的更新规则，如公式1所示。15:

$$\begin{aligned} i_t &= \sigma(W_i \cdot [h_{t-1}, [p, v, s]_t] + b_i) \\ f_t &= \sigma(W_f \cdot [h_{t-1}, [p, v, s]_t] + b_f) \\ o_t &= \sigma(W_o \cdot [h_{t-1}, [p, v, s]_t] + b_o) \end{aligned} \quad (15)$$

其中  $\sigma$  表示sigmoid函数， $h_{t-1}$  是前一个状态的输出， $W$ 是状态转移矩阵， $b$ 是偏差。

每个LSTM单元 $c_t$  的状态更新为：

$$c_t = f_t \odot c_{t-1} + i_t \odot (W_c \cdot [h_{t-1}, [p, v, s]_t] + b_c) \quad \text{或} \quad h_{t-1} = o_t \odot \tanh(c_{t-1}) \quad (16)$$

我们也在线进行训练过程，从某种意义上说，每次接收到新的输入时，我们都使用LSTM单元的先前状态和参数 $[c_{t-1}, W, b]$ 来初始化LSTM单元的周期 $t$ 。

## 4 实验

为了评估我们正式化市场观点的质量和有效性，我们使用各种实验设置进行交易模拟。

### 4.1 数据

本研究中使用的数据可在网上公开获得<sup>4</sup>。我们从Quandl API获得股票和每日交易量的历史收盘价<sup>5</sup>；Yahoo!的市值数据金融；来自PsychSignal的公司级情绪时间序列的每日计数和强度<sup>6</sup>。使用NLP技术从多个社交媒体平台计算情绪强度分数。图. 3 描绘了公共情绪数据的片段示例

<sup>4</sup> <http://github.com/fxing79/ibaa>

<sup>5</sup> <http://www.quandl.com/tools/api>

<sup>6</sup> <http://psychsignal.com>

流。市场在周末关闭，因此可以观察到相应的每周消息量周期。

我们调查了一个大约8年（2800天）的窗口。所有时间序列均在2009-10-05至2017-06-04期间进行修剪。对于缺失值，例如周末和公众假期的收盘价，我们用最近的历史数据填充他们来训练神经模型。我们用于价格和交易量的滞后值包括前4天和过去30天的移动平均值，也就是说，我们的神经模型的输入采用方程式的形式。17 和18:




图3. 通过cashtag AAPL过滤的每日推文的数量（蓝色，左）；平均情绪强度（红色，左）；净情绪极性（红色，右）；每日回报（黑色，右）在90天（2017-03-04至2017-06-04）的时间段内。所有系列都已标准化。

$$L^{0 \sim k} \text{价格}_t = (p_t, p_{t-1}, p_{t-2}, \dots, \frac{\sum_{i=1}^{30} p_i}{30}) \quad (17)$$

$$p_{t-3}, \dots, \frac{\sum_{i=1}^{30} v_i}{30}) \quad (18)$$

$$L^{0 \sim k} \text{体积}_t = (v_t, v_{t-1}, v_{t-2}, v_{t-3},$$

## 4.2 交易模拟

我们构建了由5大股票组成的虚拟投资组合：Apple Inc (AAPL)，Goldman Sachs Group Inc (GS)，Pfizer Inc (PFE)，Newmont Mining Corp (NEM) 和Starbucks Corp (SBUX)。这个随机选择涵盖纽约证券交易所和纳斯达克市场以及多元化行业，如技术，金融服务，医疗保健，非必需消费品等。在调查期间，有两个分支：6月9日AAPL的7比1分拆2014年，以及2015年4月9日SBUX的2对1拆分。每股价格根据计算所有相关变量的当前股份大小进行调整，但不考虑股息。我们将结果与两种投资组合构建策略进行对比

**1) 价值加权投资组合 (VW)：**我们根据每只股票市值的百分比每日重新投资。在这种情况下，投资组合表现将是每只股票表现的加权平均值。这个策略是基础，但实证研究 [10] 表明即使在扣除费用之前击败市场也很困难。

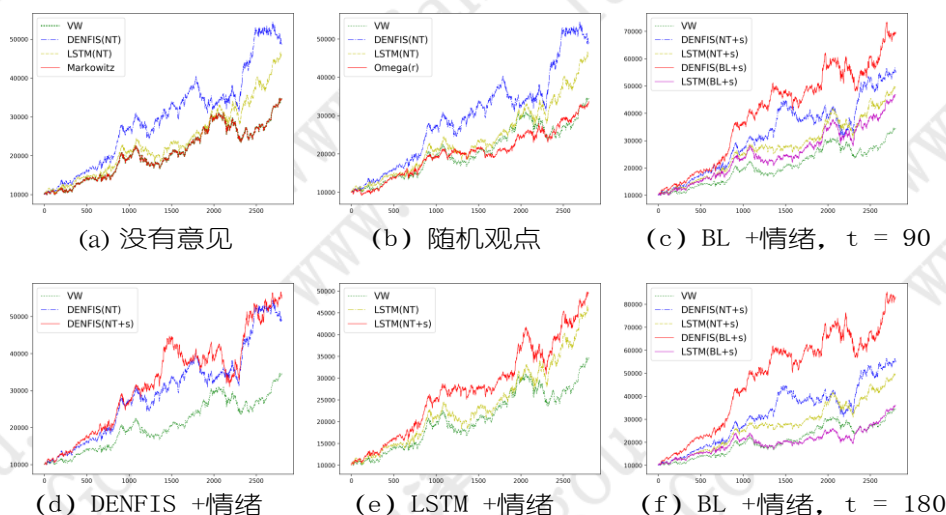


图4. 具有不同实验设置的交易模拟性能：(x轴：交易日数；y轴：累积回报)。特别是，我们的方法使用90和180天的时间跨度。神经交易的表现与时间跨度无关，因此将两种神经模型进行比较4(d) 和4(e) 分别为了更好的表现。

**2) 神经交易组合 (NT)：**我们删除市场视图的构建，并使用相同的输入直接训练每日位置的最佳权重。对于这种黑盒策略，我们无法深入了解此输出组合权重的来源。

在模拟中，我们假设没有卖空，税收或交易费用，我们假设投资组合投资是无限可分的，从10,000美元开始。我们构建没有观点的投资组合 ( $\Omega_0$ ，在这种情况下，退化投资组合相当于Markowitz的均值-方差投资组合，使用历史回报序列来估计协方差矩阵作为风险度量)，随机视图 ( $\Omega_r$ )，使用Black-Litterman模型 ( $\Omega_0$ ) 的构造的标准视图，有和没有我们的情绪引起的预期收益 ( $s$ )。交易表现如图1所示。4.

继之前的研究[13]，我们设定风险规避系数  $\delta = 0.25$  和CAPM的置信水平， $\tau = 0.05$ 。设模糊隶属函数的激活范围为  $d = 0.21$ ，从DENFIS的整个在线训练过程中得到21个模糊规则节点。此参数最小化全局投资组合权重错误。对于使用深度学习的第二个神经模型，我们堆叠两层LSTM，然后是密集连接的层。每个LSTM层有3个单元；密集连接的层有50个神经元，其设置时间大于LSTM单元的数量。我们使用向量Q的均方误差作为

损失函数和rmsprop优化器[30]训练这个架构。我们在实验中观察到快速训练误差收敛。

### 4.3 性能指标

已经提出了多种指标来评估给定投资组合的表现[5,15,31]。我们在实验中报告了四个指标。

均方根误差 (RMSE) 是近似问题的通用度量。它广泛用于具有正态分布和极少异常值的工程和数据。我们将实现的投资组合权重的RMSE计算为最佳权重:

$$\text{rmse} = \sqrt{\frac{1}{n} \sum_{i=1}^n (w_i - \hat{w}_i)^2} \quad (19)$$

年度回报 (AR) 衡量给定投资组合的盈利能力。我们计算了每年的几何平均增长率, 这也称为这2800天的复合年增长率 (CAGR)。

夏普比率 (SR) 是风险调整后的回报指标。我们选择价值加权投资组合作为基础, 因此大众的夏普比率将为1:

$$\text{SR} = \frac{(RV) e^{0.10} r_{\text{portf}} / W}{S(r_{\text{portf}} - 0.10) / (rv - w)} \quad (20)$$

SR使用每日收益的标准差作为风险度量。注意, 要区分好坏风险, 我们也可以使用下行回报的标准差[28]。我们的结果表明, 由于页数限制而未报告的Sortino比率非常接近SR, 并得出相同的结论。

最大亏损 (MDD) 衡量投资者可能的最大损失百分比:

$$\text{MDD} = \max_{0 < t < \tau} \frac{\text{价值}_t - \text{价值}_\tau}{\text{价格}_\tau} \quad (21)$$

具有大量MDD的资产分配策略面临退出的风险。表1提供指标。

### 4.4 发现

我们从图中得到了一些有趣的观察。4和表1。SR和AR通常被认为是最重要的, 此外, RMSE和MDD在我们的实验中都非常接近。RMSE与其他三个指标之间的相关性较弱, 但直观的是, 如果实现的权重接近最优权重, 则投资组合的表现应该更好。相反, LSTM模型似乎过度拟合, 因为他们接受了权重的均方误差或预期的观点回报的训练[22]。但是, 作为

表1. 各种投资组合构建策略的绩效指标，时间跨度= 90天和180天。前三个指标以粗体显示。

	RMSE	锏	MDD(%)	AR(%)
大众集团	0.8908	1.00	25.81	17.49
Markowitz90 ( $\Omega_{\varnothing}$ )	0.9062	1.00	25.81	17.51
Markowitz180 ( $\Omega_{\varnothing}$ )	0.8957	1.00	25.82	17.45
BL90 ( $\Omega_r$ )	0.9932	0.90	<b>23.47</b>	17.17
BL180 ( $\Omega_r$ )	0.9717	1.06	<b>20.59</b>	22.31
登菲斯 (nt)	0.9140	<b>2.94</b>	29.84	23.09
DENFIS(NT+s)	0.9237	<b>4.35</b>	<b>23.07</b>	<b>25.16</b>
DENFIS(BL90+s)	0.9424	1.52	24.44	<b>28.69</b>
DENFIS(BL180+s)	0.9490	<b>1.58</b>	24.19	<b>29.49</b>
LSTM(NT)	<b>0.8726</b>	1.38	25.68	22.10
LSTM(NT+s)	0.8818	1.42	25.96	23.21
LSTM(BL90+s)	<b>0.8710</b>	1.34	25.90	22.33
LSTM(BL180+s)	<b>0.8719</b>	1.07	24.88	17.68

在Sect. 4.1中提到，1，权重与日收益之间的关系是非线性的。因此，持有接近最佳权重的投资组合权重并不一定意味着AR必须更高。事实上，在资产配置研究之外使用任何看似合理的指标是危险的，例如价格变化预测的方向准确性[4,33]，评估预期的投资组合表现。

Markowitz投资组合 ( $\Omega_{\varnothing}$ ) 显示出与市场跟踪策略非常相似的行为。这与先前研究中提到的均值方差方法的有效性一致：持有Markowitz投资组合持有市场投资组合。事实上，如果CAPM成立，市场投资组合已经反映了风险溢价的调整，也就是说，市场参与者将投资于高风险资产的数量减少，因此他们的市值也会更小。

然而，Black-Litterman模型并不总能保证比Markowitz产品组合更好的性能。“垃圾进，垃圾出”仍然适用于这种情况。给定随机视图 ( $\Omega_r$ )，就SR和AR而言，它可能比市场跟随更差。吸取的教训是，如果投资者什么都不知道，那么最好不要持有任何观点并跟随市场，而不是假装知道某些事情。

在我们的实验中，DENFIS通常比LSTM模型表现更好，实现更高的SR和AR。原因可能是LSTM模型更快地适应输入数据，而金融时间序列通常非常嘈杂。ECM机制为DENFIS模型提供了收敛的学习率，这可能有利于记忆规则的稳定性。然而，重要的是要注意两种神经模型的AR随着情绪的混合而改善。用于估计资产相关性和波动性的时间跨度似乎并不那么重要。DENFIS模型在更长的时间跨度内表现更好，而LSTM



模型在更短的时间内表现更好。Markowitz投资组合受时间跨度的影响较小。

## 5 一个故事

我们正式化和计算市场观点的主要优势之一是，每日资产重新分配决策都会有一些透明度。在大多数情况下，基于机器学习算法的股票价格预测系统无法证明“为什么他认为价格会达到预测点”。与这些系统不同，我们的方法可以向专业投资者和建议寻求者讲述投资组合的故事。以2017年6月1日为例：

“2017年6月1日，我们观察到极性+1.90的正面意见164，AAPL股票的极性1.77的58个负面意见；极性值为54.7的正面意见，对GS股票的极性为1.53的37个负面意见；极性为+2.46的5个正面意见，PFE股票极性为1.33的负面意见；对NEM股票没有意见；和9个极性的正面意见+1.76，对SBUX股票的极性2.00的5个负面意见。鉴于股票的历史价格和交易量，我们有6.29%的信心，AAPL的表现将超过市场70.11%；23.50%信心GS将跑赢大市263.28%；PFE的市盈率为0.11%，表现优于市场0.50%；1.21%的信心SBUX将比市场表现优异4.57%。由于我们目前的投资组合在AAPL上投资21.56%，在GS上投资25.97%，在PFE投资29.43%，在SBUX投资23.04%，到2017年6月2日，我们应该撤回对AAPL的所有投资，占GS投资的2.76%，PFE投资的81.58%，SBUX投资的30.77%，并将其再投资于NEM。”

## 6 结论和未来的工作

在之前的研究中，考虑了财务预测的情绪信息，投资者作为市场参与者的角色通常不存在。在本文中，我们提出了一种通过将公共情绪数据流融入贝叶斯资产配置框架来整合市场情绪的新方法。

这项工作形式化情绪引发的市场观点的先驱。我们的实验表明，市场观点为资产管理提供了一种强有力的方法。我们还确认了基于社交媒体的公共情绪数据流在制定资产配置策略方面的功效。

这项工作的局限性在于我们修复了具有五种资产的投资组合，但实际上投资组合选择问题同样重要。本文不讨论如何评估情绪数据的质量。我们还没有分辨或发现意见操纵的阶段，尽管像开放网络这样的关注充满了机器人确实存在。另一个限制是没有考虑幸存者的偏见：投资组合中选择的资产可能退出市场或缺乏流动性的风险。只包括高质量的资产可以缓解这个问题。将来，我们将研究检查

使用不同的内容分析方法获得的情绪数据质量。我们还计划开发一种可以应对市场摩擦的贝叶斯资产配置模型。

## 参考

1. Angeletos, G., La'O, J. : Sentiments. *Econometrica* 81 (2) , 739-779 (2013)
2. Antweiler, W., Frank, MZ: 这些只是噪音吗? 互联网股票留言板的信息内容. *The Journal of Finance* 59 (3) , 1259-94 (2004)
3. Black, F., Litterman, R. : 资产配置: 将投资者观点与市场均衡相结合. *固定收益杂志* 1, 7-18 (1991)
4. Bollen, J., Mao, H., Zeng, X. : Twitter的情绪预示着股市. *计算科学杂志* 2 (1) , 1-8 (2011)
5. Brandt, MW: 投资组合选择问题, “金融计量经济学手册”, 第一卷. 1, 小伙子5, 第269-336页. Elsevier BV, 英国牛津 (2009年)
6. Cambria, E. : 情感计算和情绪分析. *IEEE智能系统* 31(2), 102 - 107 (2016)
7. Cambria, E., Das, D., Bandyopadhyay, S., Feraco, A. (编辑) : 情感分析的实用指南. 瑞士施普林格国际出版社 (2017年)
8. Chan, SW, Chong, MW: 财务文本中的情感分析. *决策支持系统* 94, 53-64 (2017)
9. Chaturvedi, I., Ragusa, E., Gastaldo, P., Zunino, R., Cambria, E. : 基于贝叶斯网络的极端学习机, 用于主观性检测. *富兰克林研究所杂志* 355 (4) , 1780-97 (2018)
10. Fama, EF, French, KR: 共同基金回报的横截面上的运气与技巧. *财经杂志* 65 (5) , 1915-47 (2010)
11. Gers, FA, Eck, D., Schmidhuber, J. : 将lstm应用于通过时间窗方法可预测的时间序列. 在: *ICANN, LNCS, vol. 2130. pp.669-676* (2001)
12. Greff, K., Srivastava, RK, Koutnik, J., Steunebrink, BR, Schmidhuber, J. : Lstm: 搜索空间奥德赛. *IEEE TNNLS* 28 (10) , 2222-32 (2017)
13. 他, G. , Litterman, R. : 黑色垃圾船模型组合背后的直觉. 高盛工作报告 (1999年) 。 <https://doi.org/10.2139/ssrn.334304>
14. Hommes, C. : 新帕尔格雷夫经济学词典, 第二章. 金融中的互动代理. 贝辛斯托克: Palgrave Macmillan, 2 edn. (2008年)
15. Hyndman, RJ, Koehler, AB: 另一种关于预测准确度测量的观察. *国际预测期刊* 22 (4) , 679-688 (2006)
16. Kasabov, NK, Song, Q. : Denfis: 动态演化神经模糊推理系统及其在时间序列预测中的应用. *IEEE Transactions on Fuzzy Systems* 10, 144-154 (2002)
17. Li, Q., Jiang, L., Li, P., Chen, H. : 用于预测股票走势的基于张量的学习. 在: *AAAI. 第1784-90页* (2015)
18. Markowitz, H. : 投资组合选择. *财经杂志* 7, 77-91 (1952)
19. Nguyen, TH, Shirai, K. : 基于主题建模的社交媒体情绪分析, 用于股票市场预测. 在: *ACL. pp.1354-64* (2015)
20. Nofer, M., Hinz, O. : 用twitter来预测股市: 情绪效应在哪里? 商业与信息系统工程 57 (4) , 229-242 (2015)
21. O'Connor, B., Balasubramanyan, R., Routledge, BR, Smith, NA: 从推文到民意调查: 将文本情绪与公众舆论时间序列联系起来. 在: *ICWSM. 第122-129页* (2010)

22. Pant, PN, Starbuck, WH: 森林中的无辜者: 预测和研究方法。管理杂志 16 (2), 433-460 (1990)
23. Ranco, G., Aleksovski, D., Caldarelli, G., Grcar, M., Mozetic, I.: 推特情绪对股票价格回报的影响。PLOS ONE 10 (9), 1-21 (2015)
24. Satchell, S., Scowcroft, A.: 黑色垃圾箱模型的神秘化: 管理定量和传统的投资组合构建。资产管理杂志1 (2), 138-150 (2000)
25. Shen, W., Wang, J.: 通过子集重采样进行投资组合选择。在: AAAI. pp.1517-23 (2017)
26. Si, J., Mukherjee, A., Liu, B., Li, Q., Li, H., Deng, X.: 基于主题的基于Twitter的情绪进行股票预测。在: ACL. 第24-29页 (2013年)
27. Smilovic, J., Grcar, M., Lavrac, N., Znidarsic, M.: Predictive sentiment analysis  
推文: 股市应用。在: LNCS. 第一卷。7947, 第77-88页。柏林施普林格 (2013年)
28. Sortino, FA, Price, LN: 下行风险框架中的绩效评估。The Journal of Investing 3, 59-64 (1994)
29. Steinbach, MC: Markowitz再次访问: 金融投资组合分析中的均值 - variance模型。SIAM Review 43 (1), 31-85 (2001)
30. Tieleman, T., Hinton, GE: 讲座6.5-rmsprop: 将梯度除以其最近幅度的运行平均值。COURSERA: 用于机器学习的神经网络 (2012)
31. Xing, FZ, Cambria, E., Welsh, RE: 基于自然语言的财务预测: 一项调查。人工智能评论50 (1), 49-73 (2018)
32. Xing, FZ, Cambria, E., Zou, X. 用模糊神经网络预测进化混沌时间序列。在: IJCNN. 第3176-83页 (2017)
33. Yoshihara, A., Seki, K., Uehara, K.: 利用新闻事件的时间属性进行股票市场预测。人工智能研究5 (1), 103-110 (2016)
34. Zhang, W., Skiena, S.: 利用博客和新闻情绪的交易策略。在: ICWSM. 第375-378页 (2010)